



**Universidad
Europea**

UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

GRADO EN MÁSTER DATA SCIENCE

PROYECTO FIN DE GRADO

PREDICCIÓN INTELIGENTE DE PRECIOS EN AIRBNB MADRID

KATHERINE LÓPEZ RAMÍREZ

Dirigido por

DIRECTOR: ÁLVARO SÁNCHEZ PÉREZ

CODIRECTOR: CARMEN ALONSO

CURSO 2024-2025

TÍTULO: PREDICCIÓN INTELIGENTE DE PRECIOS AIRBNB MADRID

AUTOR: KATHERINE LÓPEZ RAMÍREZ

TITULACIÓN: MÁSTER DATA SCIENCE

DIRECTOR/ES DEL PROYECTO: INGENIERO ÁLVARO SÁNCHEZ PÉREZ
INGENIERA CARMEN ALONSO

FECHA: SEPTIEMBRE 2025

RESUMEN

El crecimiento sostenido del turismo en Madrid y la consolidación de plataformas como Airbnb han generado un mercado altamente competitivo, donde la fijación de precios se convierte en un desafío complejo. Los anfitriones deben equilibrar factores como la ubicación, las características del alojamiento y la estacionalidad, mientras que turistas e inversores requieren referencias fiables para tomar decisiones informadas.

El presente proyecto aborda este problema mediante el desarrollo de un modelo predictivo basado en técnicas de aprendizaje automático. Utilizando datos públicos de Inside Airbnb, que incluyen características de los anuncios y precios diarios, se realizó un proceso completo de limpieza, análisis exploratorio y eliminación de valores atípicos, garantizando la calidad de la información. Posteriormente, se entrenaron y compararon distintos algoritmos (CatBoost, XGBoost y Random Forest), siendo este último el que ofreció los mejores resultados.

El modelo final de Random Forest alcanzó un rendimiento destacado ($MAE \approx 12,90$ €, $RMSE \approx 18,99$ €, $R^2 \approx 0,883$), lo que demuestra su capacidad para realizar predicciones precisas y robustas. Además, se desarrolló una interfaz de usuario sencilla e intuitiva que permite realizar consultas prácticas, facilitando la interpretación de los resultados.

En conclusión, el proyecto aporta una solución útil y escalable que contribuye a optimizar la gestión de precios en el sector turístico, beneficiando a anfitriones, turistas e inversores.

Palabras clave: Airbnb, predicción de precios, aprendizaje automático, Random Forest, estacionalidad, Data Science

ABSTRACT

The steady growth of tourism in Madrid and the rise of platforms such as Airbnb have created a highly competitive market, where price setting has become a complex challenge. Hosts must balance factors such as location, property characteristics, and seasonality, while tourists and investors need reliable references to make informed decisions.

This project addresses the problem by developing a predictive model based on machine learning techniques. Using public data from Inside Airbnb, which includes listing characteristics and daily prices, a complete process of data cleaning, exploratory analysis, and outlier removal was carried out to ensure information quality. Subsequently, different algorithms (CatBoost, XGBoost, and Random Forest) were trained and compared, with the latter achieving the best performance.

The final Random Forest model achieved outstanding results ($MAE \approx €12.90$, $RMSE \approx €18.99$, $R^2 \approx 0.883$), demonstrating its ability to deliver precise and robust predictions. In addition, a simple and intuitive user interface was developed to allow practical queries and facilitate interpretation of the results.

In conclusion, the project provides a useful and scalable solution that helps optimize price management in the tourism sector, delivering benefits to hosts, tourists, and investors alike.

Keywords: Airbnb, price prediction, machine learning, Random Forest, seasonality, Data Science

AGRADECIMIENTOS

Deseo expresar mi más sincero agradecimiento a la ingeniera Carmen Alonso, quien dedicó parte de su tiempo extra para acompañarme en este proceso. Su constante apoyo, cercanía y diligencia han sido fundamentales para culminar este Trabajo de Fin de Máster con éxito. Más allá de la orientación académica, valoro profundamente la energía positiva, el compromiso y la dedicación con los que me ha acompañado en cada etapa.

Agradezco también a mi director de programa Álvaro Sánchez, por su comprensión y paciencia, así como por las facilidades otorgadas en los plazos para la entrega de este trabajo. Su apoyo ha sido clave para poder adaptarme a las circunstancias y finalizar este proyecto.

Finalmente, extendiendo mi gratitud a todos los profesores del máster, quienes con sus enseñanzas y conocimientos hicieron posible que adquiriera las competencias necesarias para desarrollar este proyecto.

DEDICATORIA

Este trabajo está dedicado, en primer lugar, a mi hijo Cristian. Gracias, hijo, porque incluso en los momentos más difíciles siempre encontraste la manera de animarme, “mamá, recuerda terminar tu trabajo”. Durante todo el máster fuiste mi inspiración constante, impulsándome a estudiar, a presentar cada entrega y a no rendirme. Hoy, aunque me acompañas desde el cielo, sigues dándome la fuerza para levantarme y culminar este proyecto que también es tuyo.

Dedico este logro a mi esposo Juan y a mis padres, quienes con amor, paciencia y apoyo incondicional me sostuvieron cuando sentí que no podía continuar. En cada instante me brindaron la motivación necesaria para seguir adelante, aun cuando la vida pesaba demasiado.

A mi hermosa familia, a los que están y a Cris, que me mira desde el cielo, este trabajo es para ustedes.

TABLA RESUMEN

DATOS	
Nombre y apellidos:	Katherine López Ramírez
Título del proyecto:	Predicción inteligente de precios en Airbnb Madrid
Directores del proyecto:	Álvaro Sánchez Pérez Carmen Alonso
El proyecto se ha realizado en colaboración de una empresa o a petición de una empresa:	NO
El proyecto ha implementado un producto: (esta entrada se puede marcar junto a la siguiente)	SI
El proyecto ha consistido en el desarrollo de una investigación o innovación: (esta entrada se puede marcar junto a la anterior)	SI
Objetivo general del proyecto:	Desarrollar un modelo predictivo en Machine Learning para estimar con precisión los precios de Airbnb en Madrid, considerando ubicación, características del alojamiento y estacionalidad.

Índice

RESUMEN	3
ABSTRACT.....	4
TABLA RESUMEN	7
Capítulo 1. RESUMEN DEL PROYECTO	12
1.1 Contexto y justificación	12
1.2 Planteamiento del problema	12
1.3 Objetivos del proyecto	12
1.4 Resultados obtenidos	12
1.5 Estructura de la memoria	13
Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE	14
2.1 Estado del arte	14
2.2 Contexto y justificación	14
2.3 Planteamiento del problema	14
Capítulo 3. OBJETIVOS.....	16
3.1 Objetivo general.....	16
3.2 Objetivos específicos	16
3.3 Beneficios del proyecto	16
Capítulo 4. DESARROLLO DEL PROYECTO	17
4.1 Planificación del proyecto	17
4.2 Descripción de la solución, metodologías y herramientas empleadas	18
4.2.1 Metodología de trabajo.....	18
4.2.2 Herramientas utilizadas.....	19
4.2.3 Limpieza y preparación de datos.....	20
4.2.4 Análisis exploratorio	25
4.2.5 Modelados predictivos	26
4.2.6 Interpretación del modelo Random Forest	27
4.2.7 Interfaz de usuario	33
4.3 Recursos requeridos	35
4.4 Presupuesto	35
4.5 Viabilidad	35

4.6	Resultados del proyecto	36
Capítulo 5.	DISCUSIÓN.....	38
5.1	Utilidad y pertinencia de la metodología	38
5.2	Limitaciones del estudio	38
5.3	Limitaciones tecnológicas	38
5.4	Adaptaciones y cambios en el desarrollo	39
5.5	Impacto y valor del proyecto	39
Capítulo 6.	CONCLUSIONES.....	40
6.1	Conclusiones del trabajo	40
6.2	Conclusiones personales.....	40
Capítulo 7.	FUTURAS LÍNEAS DE TRABAJO	42
Capítulo 8.	REFERENCIAS	43
Capítulo 9.	ANEXOS	44

Índice de Figuras

Ilustración 1. Cronograma del proyecto de predicción de precios en Airbnb Madrid, con fases y horas estimadas (julio–agosto). Fuente: elaboración propia.	18
Ilustración 2. Tecnologías y librerías utilizadas en el desarrollo del proyecto. Fuente: elaboración propia.	19
Ilustración 3. Boxplot de precios de los alojamientos (con outliers). Fuente: elaboración propia.	21
Ilustración 4. Boxplot de precios en los 15 barrios con mayor número de alojamientos. Fuente: elaboración propia.	22
Ilustración 5. Distribución de precios por tipo de alojamiento en Madrid. Fuente: elaboración propia.	23
Ilustración 6. Impacto de los outliers en los precios promedio mensuales de los barrios más frecuentes. Fuente: elaboración propia.	24
Ilustración 7. Distribución de precios promedio mensual por barrio (top 20) tras la limpieza de outliers. Fuente: elaboración propia.	24
Ilustración 8. Mapa de calor por precios promedio de los alojamientos en Madrid. Fuente: elaboración propia.	25
Ilustración 9. Comparación de desempeño de modelos de predicción (CatBoost, XGBoost y Random Forest). Fuente: elaboración propia.	26
Ilustración 10. Importancia de las 15 variables principales en el modelo de predicción. Fuente: elaboración propia.	28
Ilustración 11. Matriz de correlación de variables numéricas utilizadas en el modelo Random Forest. Fuente: elaboración propia.	29
Ilustración 12. Comparación entre precio real y precio predicho por el modelo Random Forest. Fuente: elaboración propia.	30
Ilustración 13. Distribución del error absoluto en la predicción de precios. Fuente: elaboración propia.	31
Ilustración 14. Top 15 barrios con mayor error absoluto promedio en la predicción. Fuente: elaboración propia.	32
Ilustración 15. Interfaz de la aplicación para la predicción de precios en Airbnb Madrid. Fuente: elaboración propia.	34
Ilustración 16. Visualización geográfica de barrios de Madrid en la herramienta interactiva. Fuente: elaboración propia.	34

Capítulo 1. RESUMEN DEL PROYECTO

1.1 Contexto y justificación

El turismo en Madrid ha experimentado un crecimiento sostenido en los últimos años, lo que ha impulsado el uso de plataformas como Airbnb. Sin embargo, la fijación de precios en un mercado dinámico y competitivo representa un desafío.

Este proyecto surge como respuesta a dicha necesidad, ofreciendo una herramienta que contribuye a:

- Anfitriones: ajustar precios de forma óptima según zona y estacionalidad.
- Turistas: identificar mejores alternativas de alojamiento en función de precio y localización.
- Inversores: tomar decisiones estratégicas sobre dónde invertir y qué rendimiento esperar.

1.2 Planteamiento del problema

La ausencia de un modelo robusto que considere múltiples factores (barrio, características del alojamiento, estacionalidad, entre otros) limita la capacidad de los actores del mercado para fijar precios justos. Esto genera incertidumbre, pérdida de competitividad y oportunidades de mejora en la experiencia turística.

1.3 Objetivos del proyecto

Objetivo general

Desarrollar un modelo de predicción que estime el precio óptimo de alojamientos en Airbnb Madrid, incorporando variables contextuales y temporales.

Objetivos específicos

- Analizar y limpiar las bases de datos de Airbnb.
- Explorar y visualizar la información relevante sobre barrios, precios y estacionalidad.
- Entrenar y comparar modelos de Machine Learning (CatBoost, XGBoost y Random Forest).
- Seleccionar el modelo más preciso y generar una herramienta de predicción práctica.

1.4 Resultados obtenidos

El modelo seleccionado, Random Forest con codificación ordinal, alcanzó métricas destacadas en predicción:

- MAE: 12.90 €
- RMSE: 18.99 €
- R^2 : 0.883

Estos resultados muestran un alto grado de precisión y utilidad práctica, permitiendo recomendaciones personalizadas de precios y comparativas entre barrios de Madrid.

1.5 Estructura de la memoria

La memoria se organiza de la siguiente forma:

- Capítulo 1: Introducción. Contexto, justificación, planteamiento del problema y estructura del documento.
- Capítulo 2: Estado del arte. Revisión de literatura y enfoques de pricing en plataformas P2P.
- Capítulo 3: Objetivos. Objetivo general, objetivos específicos y beneficios esperados.
- Capítulo 4: Desarrollo del proyecto. Metodología (CRISP-DM), datos, limpieza, EDA, modelado, evaluación e interfaz.
- Capítulo 5: Discusión. Interpretación crítica de resultados, decisiones tomadas y limitaciones.
- Capítulo 6: Conclusiones. Logros, aportaciones y validación del cumplimiento de objetivos.
- Capítulo 7: Líneas futuras. Mejoras, escalabilidad y extensiones del sistema.
- Capítulo 8: Referencias. Fuentes bibliográficas y documentales utilizadas.
- Capítulo 9: Anexos. Material complementario (disponible en el repositorio de GitHub).

Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE

2.1 Estado del arte

En los últimos años, el auge de plataformas de economía colaborativa como Airbnb ha transformado el sector turístico. Este fenómeno ha generado un vasto campo de investigación en torno a la fijación dinámica de precios, la ocupación y la competitividad del mercado de alojamientos.

La literatura revisada destaca tres enfoques principales:

- Modelos descriptivos, que analizan tendencias de precios y demanda a partir de datos históricos.
- Modelos de predicción, que emplean técnicas de Machine Learning para estimar precios en función de características del alojamiento y su contexto.
- Modelos de optimización, que incorporan estrategias de pricing dinámico para maximizar ingresos.

Diversos estudios han demostrado que factores como la localización, el tipo de habitación, la estacionalidad y la reputación del anfitrión influyen de manera significativa en el precio. Sin embargo, aún existe una brecha en el desarrollo de modelos que integren estas variables de manera conjunta y que resulten aplicables en un caso práctico para la ciudad de Madrid.

2.2 Contexto y justificación

El crecimiento del turismo en Madrid y la fuerte presencia de Airbnb plantean la necesidad de herramientas que faciliten la toma de decisiones en un mercado altamente competitivo.

El presente proyecto busca aportar un modelo predictivo de precios que tenga utilidad en distintos ámbitos:

- Anfitriones: optimizar sus tarifas en función de la zona, la temporada y las características de su propiedad.
- Turistas: identificar barrios y periodos con precios más convenientes.
- Inversores: evaluar zonas con mayor potencial de rentabilidad.

2.3 Planteamiento del problema

La fijación de precios en Airbnb Madrid presenta limitaciones importantes:

- La información disponible es abundante, pero dispersa y con presencia de valores atípicos.
- No existen modelos unificados que integren factores espaciales (barrios), temporales (estacionalidad) y características del alojamiento en una predicción coherente.
- La ausencia de estas herramientas genera dificultades tanto para anfitriones como para turistas e inversores, afectando la competitividad del mercado y la transparencia de la oferta.

Este proyecto surge como respuesta a dicha problemática, con el objetivo de construir un modelo predictivo sólido que aproveche los datos disponibles y genere valor práctico para los distintos actores del ecosistema turístico.

Capítulo 3. OBJETIVOS

3.1 Objetivo general

Analizar y predecir los precios de alojamientos en Airbnb Madrid en función de la zona geográfica, la estacionalidad turística y las características del inmueble, aplicando técnicas de machine learning.

3.2 Objetivos específicos

Para alcanzar el objetivo general, se han definido los siguientes objetivos concretos:

- Analizar la información de Inside Airbnb para comprender los factores que influyen en el precio de los alojamientos.
- Depurar y transformar los datos, eliminando valores atípicos y nulos, e integrando la dimensión temporal de la estacionalidad.
- Implementar y comparar diferentes algoritmos de Machine Learning (CatBoost, XGBoost y Random Forest) para identificar el modelo con mejor desempeño predictivo.
- Validar el modelo seleccionado mediante métricas de error (MAE, RMSE) y ajuste (R^2), asegurando precisión y robustez.
- Desarrollar una funcionalidad práctica que permita consultar precios estimados y compararlos entre barrios, facilitando la toma de decisiones.

3.3 Beneficios del proyecto

El desarrollo de este proyecto aporta beneficios en tres dimensiones:

- Para los anfitriones: optimizar la fijación de precios en función de la zona y la estacionalidad, aumentando competitividad y rentabilidad.
- Para los turistas: identificar barrios alternativos con precios más accesibles y ajustados, favoreciendo una mejor planificación del viaje.
- Para los inversores: evaluar con mayor precisión qué zonas de Madrid presentan mayor potencial de rentabilidad en el mercado de alquiler turístico.

Capítulo 4. DESARROLLO DEL PROYECTO

4.1 Planificación del proyecto

El proyecto se desarrolló siguiendo una secuencia lógica de fases que garantizó una construcción sólida del modelo predictivo y un análisis exhaustivo de los datos:

1. Estudio del estado del arte y definición del problema

- Revisión de la literatura sobre pricing en plataformas de economía colaborativa.
- Identificación del reto de fijación de precios en Airbnb como un problema multivariable con fuerte dependencia de factores geográficos, estructurales y de estacionalidad.

2. Obtención y exploración de datos

- Descarga de datasets públicos de Inside Airbnb: listings.csv (características de los anuncios y anfitriones) y calendar.csv (precios diarios).
- Exploración inicial para identificar inconsistencias, nulos y outliers.

3. Limpieza y preparación de datos

- Selección de variables relevantes.
- Transformación de precios a formato numérico.
- Tratamiento de valores nulos y codificación de variables categóricas.
- Eliminación de outliers a nivel global y por barrio para asegurar distribuciones realistas.

4. Análisis exploratorio y visualizaciones

- Distribución de precios a nivel global y por barrio.
- Comparativa por tipo de alojamiento.
- Mapas de calor para visualizar diferencias espaciales.
- Boxplots de precios promedio mensuales en barrios con mayor número de registros.

5. Modelado y evaluación

- Entrenamiento y comparación de tres modelos representativos: CatBoost, XGBoost y Random Forest.
- Selección del modelo óptimo en función de métricas de error y capacidad de generalización.

6. Resultados y conclusiones

- Análisis de métricas de rendimiento.
- Identificación de variables más influyentes.
- Pruebas de predicción práctica y utilidad del sistema.




Ilustración 1. Cronograma del proyecto de predicción de precios en Airbnb Madrid, con fases y horas estimadas (julio-agosto). Fuente: elaboración propia.

4.2 Descripción de la solución, metodologías y herramientas empleadas

4.2.1 Metodología de trabajo

El desarrollo del proyecto se ha basado en la metodología CRISP-DM (Cross Industry Standard Process for Data Mining), un estándar ampliamente utilizado en proyectos de ciencia de datos. Esta metodología propone un enfoque estructurado y cíclico que permite avanzar de manera ordenada desde la definición del problema hasta la implementación de soluciones, garantizando rigor analítico y flexibilidad en la adaptación a los datos disponibles.

Las fases principales de CRISP-DM y su aplicación en este trabajo han sido:

- Comprensión del problema: análisis del contexto de la fijación de precios en Airbnb Madrid, identificando la necesidad de predecir precios óptimos considerando factores geográficos, estructurales y estacionales.
- Preparación de datos: integración de los datasets públicos de Inside Airbnb, limpieza de outliers, imputación de valores nulos y codificación de variables categóricas.
- Análisis exploratorio: estudio de la distribución de precios, visualización de diferencias por barrio y tipo de alojamiento, y detección de patrones estacionales.
- Modelado y comparación de algoritmos: entrenamiento de tres modelos representativos —CatBoost, XGBoost y Random Forest— aplicando técnicas de encoding específicas para cada uno.
- Evaluación y selección: comparación de métricas (MAE, RMSE y R^2) para seleccionar el modelo óptimo, priorizando precisión y capacidad de generalización.

- Interpretación de resultados: análisis de las variables más influyentes en el precio, visualización de errores, y prueba de predicciones en escenarios prácticos para demostrar la utilidad del sistema.

4.2.2 Herramientas utilizadas

En cuanto a las herramientas empleadas, se ha trabajado en Python 3.13.2 dentro de un entorno Jupyter Notebook, apoyado en las siguientes librerías principales:

- pandas, NumPy → limpieza, transformación y análisis de datos.
- matplotlib, seaborn, plotly → generación de visualizaciones estáticas e interactivas.
- scikit-learn → preprocesamiento, métricas y modelado con Random Forest.
- xgboost y catboost → implementación de modelos de gradient boosting.
- category_encoders → codificación de variables categóricas con Target Encoding.
- Streamlit → despliegue web y visualización interactiva del modelo (UI con selectores, métricas y tablas en tiempo real).
- PyDeck (deck.gl) → visualización geográfica: capas GeoJSON para resaltar barrios (elegido y alternativas) en el mapa.

Este enfoque metodológico ha permitido garantizar la trazabilidad del trabajo, replicabilidad de los resultados y claridad en cada fase del proceso de desarrollo.



Ilustración 2. Tecnologías y librerías utilizadas en el desarrollo del proyecto. Fuente: elaboración propia.

4.2.3 Limpieza y preparación de datos

La preparación de los datos fue una de las fases más críticas del proyecto, ya que de ella dependía la calidad del modelo predictivo. Se trabajó inicialmente con dos bases proporcionadas por Inside Airbnb:

- listings.csv → información de los anuncios y características de anfitriones.
- calendar.csv → precios diarios de los alojamientos, que posteriormente permitieron calcular la estacionalidad.

Proceso de limpieza realizado

1. Selección de variables relevantes

Se redujo el dataset listings.csv que tenía 79 columnas a 26 columnas clave, priorizando aquellas que aportaban valor al modelo: características del inmueble (número de habitaciones, baños, capacidad), métricas del anfitrión (superhost, tasas de respuesta/aceptación), variables de reseñas y localización (barrio).

2. Transformación de precios

- Conversión de los precios desde formato texto (ej. "\$120") a valores numéricos.
- Creación de la variable precio_promedio_mensual, que pasó a ser la variable objetivo del modelo.

3. Manejo de nulos

- Eliminación de registros sin reseñas.
- Eliminación de entradas con datos críticos vacíos (ej. bedrooms, bathrooms), que resultaban fundamentales para la predicción.

4. Normalización de campos del host

- Tasas de respuesta y aceptación → transformadas a valores numéricos entre 0 y 100.
- Variables booleanas → transformadas a binario (1 para "sí", 0 para "no").

5. Tratamiento de outliers

El mayor reto de esta fase fueron los precios atípicos. Se aplicó una eliminación en dos niveles:

- Global (dataset listings) → detección de precios extremos superiores a 20.000 €, claramente irreales.
- Por barrio (dataset unificado con calendar) → ajuste más fino, eliminando valores desproporcionados dentro de cada zona.

4.2.3.1 Análisis de outliers en precios




Ilustración 3. Boxplot de precios de los alojamientos (con outliers). Fuente: elaboración propia.

La (Ilustración 3), muestra precios llegando a más de 20.000 € por noche

El análisis inicial mostró que:

- Precio mínimo: 8 €
- Precio máximo: 23.124 €
- Media: 130 €
- Mediana: 96 €
- Límite superior estadístico: 248 €
- Se identificaron 1.035 precios extremos que sobrepasaban los límites normales.

Conclusión: la existencia de precios tan desorbitados distorsiona la media y genera distribuciones irreales, por lo que fue necesario eliminarlos.

4.2.3.2 Distribución de precios por barrio

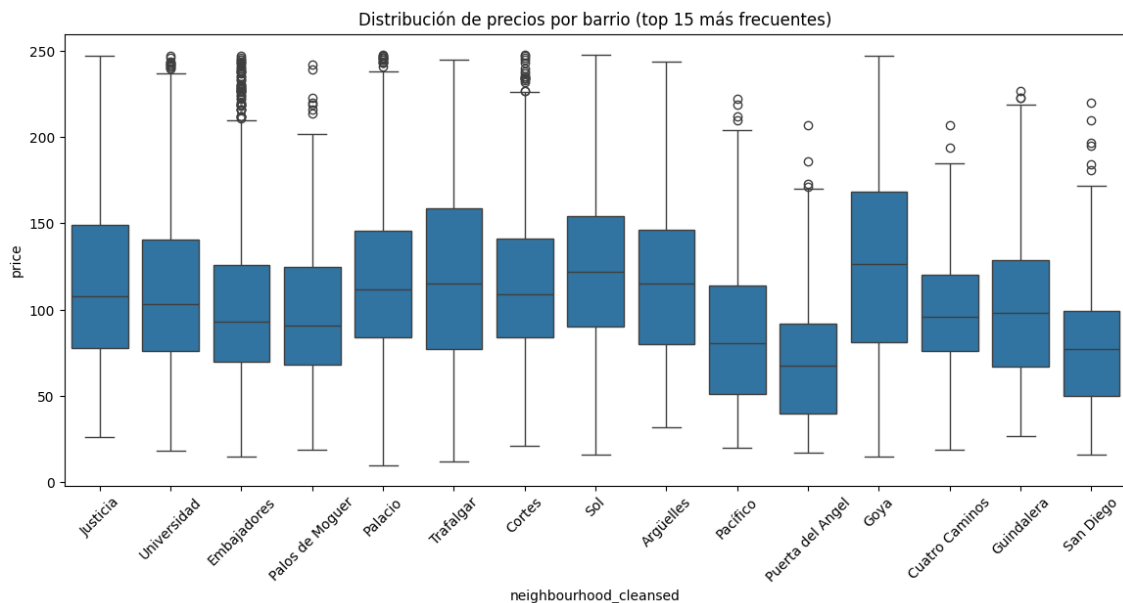


Ilustración 4. Boxplot de precios en los 15 barrios con mayor número de alojamientos. Fuente: elaboración propia.

El gráfico confirma que los precios dependen fuertemente del barrio:

- Zonas como Goya, Sol y Trafalgar presentan precios más altos y mayor dispersión.
- En contraste, Puerta del Ángel, San Diego o Pacífico muestran precios más bajos y estables.

Esta observación justificó mantener la variable `neighbourhood_cleanse` como una de las más influyentes del modelo.

4.2.3.3 Distribución de precios por tipo de alojamiento

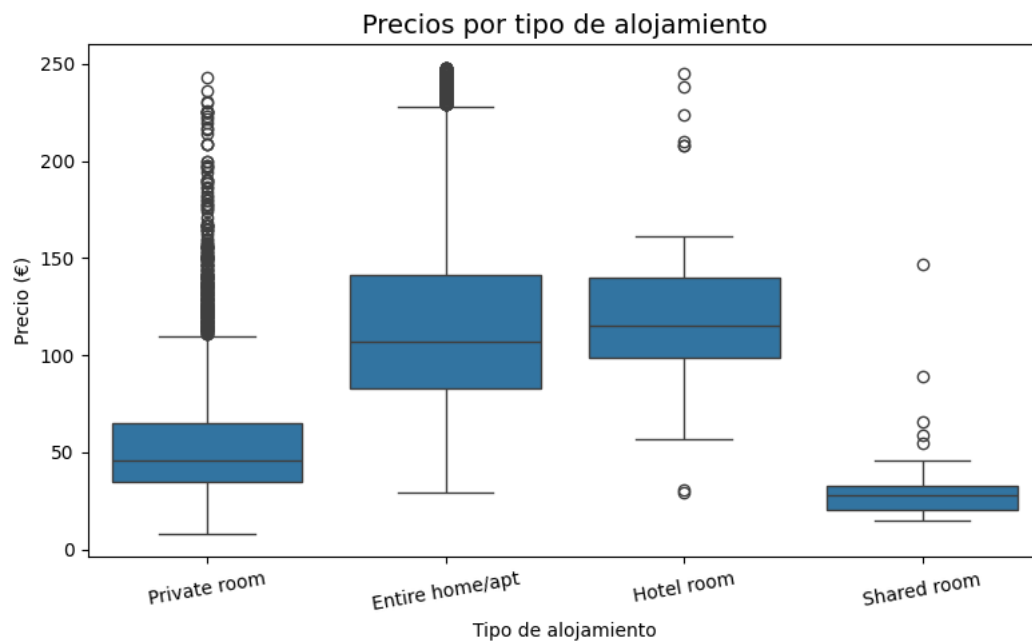


Ilustración 5. Distribución de precios por tipo de alojamiento en Madrid. Fuente: elaboración propia.

El análisis mostró un patrón coherente:

- Entire home/apt (apartamento entero) → mayor mediana (~100 €).
- Private room → precios intermedios, mayoría entre 30–60 €.
- Shared room → opción más barata (mediana ~25 €).
- Hotel room → precios intermedios-altos con mayor dispersión.

No obstante, también se detectaron outliers (ej. habitaciones privadas con precios superiores a apartamentos completos), atribuibles a errores de carga o anuncios poco representativos.

4.2.3.4 Impacto de la limpieza de outliers




Ilustración 6. Impacto de los outliers en los precios promedio mensuales de los barrios más frecuentes. Fuente: elaboración propia.




Ilustración 7. Distribución de precios promedio mensual por barrio (top 20) tras la limpieza de outliers. Fuente: elaboración propia.

- Antes de limpiar por barrio: se observaron en la (Ilustración 6), precios irrealmente altos después de la unión de listings con calendar (ej. más de 12.000 €/mes en barrios concretos).
- Después de limpiar por barrio: como se ve en la (Ilustración 7), la distribución se volvió coherente, manteniendo diferencias lógicas entre zonas pero eliminando valores irrealmente altos.

4.2.3.5 Conclusión de la preparación de datos

La unión de los datasets (listings + calendar), junto con la eliminación de outliers globales y por barrio, permitió obtener una base de datos realista y robusta. Esto fue clave para:

- Evitar que los modelos se vieran sesgados por valores irreales.
- Capturar patrones geográficos y estacionales reales.
- Mejorar la calidad y fiabilidad de las predicciones.

Eliminación de outliers por barrio: Tras la integración de ambos datasets, se aplicó un segundo filtrado, esta vez a nivel de barrio, con el fin de eliminar valores atípicos locales y garantizar que los precios reflejaran tendencias realistas en cada zona de Madrid.

Finalmente, se generó el archivo `df_modelo.csv`, con el dataset limpio, preparado y listo para el modelado. De esta forma, se obtuvo un dataset final robusto, coherente y listo para el análisis exploratorio y la fase de modelado predictivo.

4.2.4 Análisis exploratorio

Como parte del análisis exploratorio de datos (EDA, Exploratory Data Analysis), se realizó una visualización espacial mediante un mapa de calor que representa el precio promedio por barrio en la ciudad de Madrid.

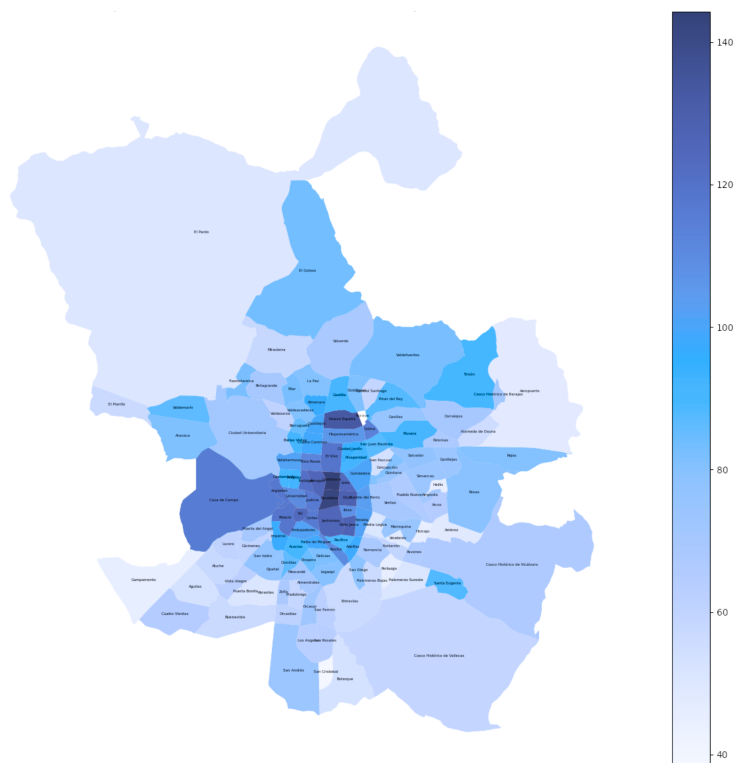


Ilustración 8. Mapa de calor por precios promedio de los alojamientos en Madrid. Fuente: elaboración propia.

En el mapa (Ilustración 8) se observa claramente cómo la ubicación geográfica influye en el valor de los alojamientos:

- Los barrios céntricos, como Justicia, Sol, Embajadores y Palacio, aparecen en tonos más oscuros, lo que refleja precios medios significativamente más altos. Esto coincide con la alta demanda turística y la proximidad a los principales atractivos de la ciudad.
- A medida que se avanza hacia la periferia, los precios descienden, representados en tonos más claros, lo que indica una mayor accesibilidad económica en esas zonas.
- La escala lateral de colores permite identificar un rango de valores que va aproximadamente de 40 € a más de 140 € por noche en promedio, lo que demuestra la gran dispersión de precios dentro del mercado de Airbnb en Madrid.

Conclusión: Este análisis exploratorio confirma que la variable `neighbourhood_cleansed` es clave en el modelo predictivo, ya que la localización del inmueble representa uno de los factores más determinantes en la fijación de precios. La dimensión espacial obtenida a partir del mapa de calor permite identificar claramente zonas premium frente a zonas más asequibles, aportando un insumo fundamental tanto para anfitriones como para inversores y turistas.

4.2.5 Modelados predictivos

Para evaluar el rendimiento del sistema de predicción, se entrenaron y compararon tres algoritmos representativos de machine learning: CatBoost, XGBoost y Random Forest, todos aplicados sobre el dataset limpio y enriquecido con información de estacionalidad mensual.




Ilustración 9. Comparación de desempeño de modelos de predicción (CatBoost, XGBoost y Random Forest). Fuente: elaboración propia.

Los resultados obtenidos en el conjunto de prueba fueron los siguientes:

- CatBoost → MAE: 19,75 €, RMSE: 28,81 €, R^2 : 0,731
- XGBoost → MAE: 15,91 €, RMSE: 23,04 €, R^2 : 0,828
- **Random Forest → MAE: 12,90 €, RMSE: 18,99 €, R^2 : 0,883**

La comparación gráfica (Ilustración 9) y numérica evidencia que el Random Forest es el modelo con mejor desempeño global, obteniendo los valores más bajos de error absoluto medio (MAE) y raíz del error cuadrático medio (RMSE), junto con el mayor coeficiente de determinación (R^2).

Estrategia de codificación

Cada modelo requirió un tratamiento diferenciado de las variables categóricas, acorde con sus características internas:

- **CatBoost:** permite trabajar directamente con variables categóricas, incorporando un mecanismo interno de codificación eficiente.
- **XGBoost:** no admite variables categóricas de forma nativa, por lo que se aplicó Target Encoding, transformando las categorías en valores numéricos representativos en función de la media del target.
- **Random Forest:** se utilizó Ordinal Encoding, una codificación simple que mantiene un buen equilibrio entre eficiencia y rendimiento, evitando problemas de alta cardinalidad que podrían surgir con OneHot o Target Encoding.

Decisión final

La estrategia de comparación mostró que Random Forest no solo ofrece el mejor rendimiento cuantitativo, sino también la mayor estabilidad y robustez. Esto lo convierte en la opción más adecuada para el objetivo del proyecto: predecir de forma precisa y consistente los precios de alojamientos en Airbnb Madrid, considerando factores espaciales y estacionales.

4.2.6 Interpretación del modelo Random Forest

Importancia de las variables: El modelo Random Forest permitió identificar las variables con mayor peso en la predicción del precio (Ilustración 10).

- `room_type` aparece como la variable más determinante, lo que confirma que el tipo de alojamiento (habitación privada, apartamento completo, etc.) es clave para el mercado.
- `review_scores_location` y `bedrooms` ocupan el segundo y tercer lugar, evidenciando la relevancia tanto de la ubicación percibida como del tamaño de la vivienda.
- Variables estructurales como `bathrooms` y `accommodates` complementan la explicación, mientras que la reputación del anfitrión (reseñas de limpieza, comunicación, número de reseñas) también influye de manera significativa.

Estos resultados reflejan la lógica del mercado inmobiliario y turístico: el precio de un Airbnb en Madrid depende de una combinación de tipo de alojamiento, localización y reputación.

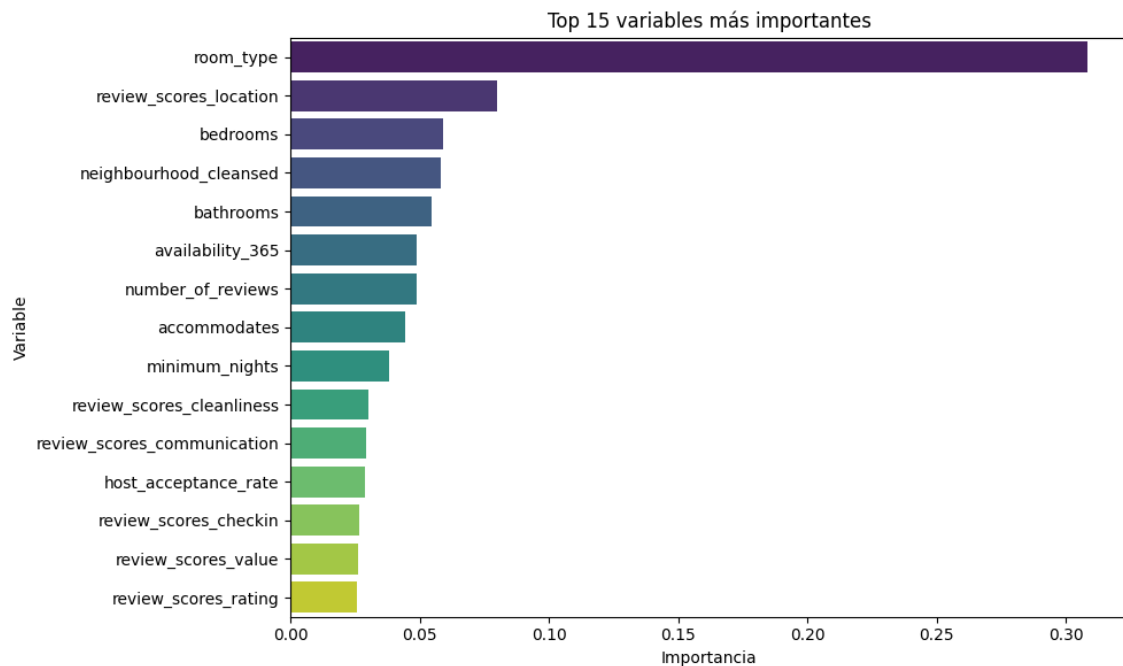


Ilustración 10. Importancia de las 15 variables principales en el modelo de predicción. Fuente: elaboración propia.

Matriz de correlación: En la (Ilustración 11) se presenta la matriz de correlación entre variables numéricas del modelo.

- Se observan relaciones fuertes entre variables estructurales como `accommodates`, `bedrooms` y `beds`.
- Las reseñas también muestran alta correlación entre sí (`review_scores_rating`, `review_scores_accuracy`, `review_scores_cleanliness`, etc.), lo cual es esperable ya que representan distintas dimensiones de la satisfacción del cliente.
- Otras variables como `minimum_nights`, `availability_365` o `instant_bookable` presentan correlaciones más débiles, lo que confirma que aportan información complementaria.

Aunque la multicolinealidad podría ser un problema en modelos lineales, Random Forest tolera estas redundancias y selecciona automáticamente las variables más útiles, lo que refuerza su robustez.




Ilustración 11. Matriz de correlación de variables numéricas utilizadas en el modelo Random Forest. Fuente: elaboración propia.

Ajuste del modelo: La (Ilustración 12) muestra la relación entre precio real y precio predicho. Los puntos se alinean mayoritariamente con la diagonal de referencia, indicando un excelente ajuste.

Esto confirma que el modelo captura de manera precisa la tendencia general de precios en Madrid, desde alojamientos económicos hasta propiedades de lujo.

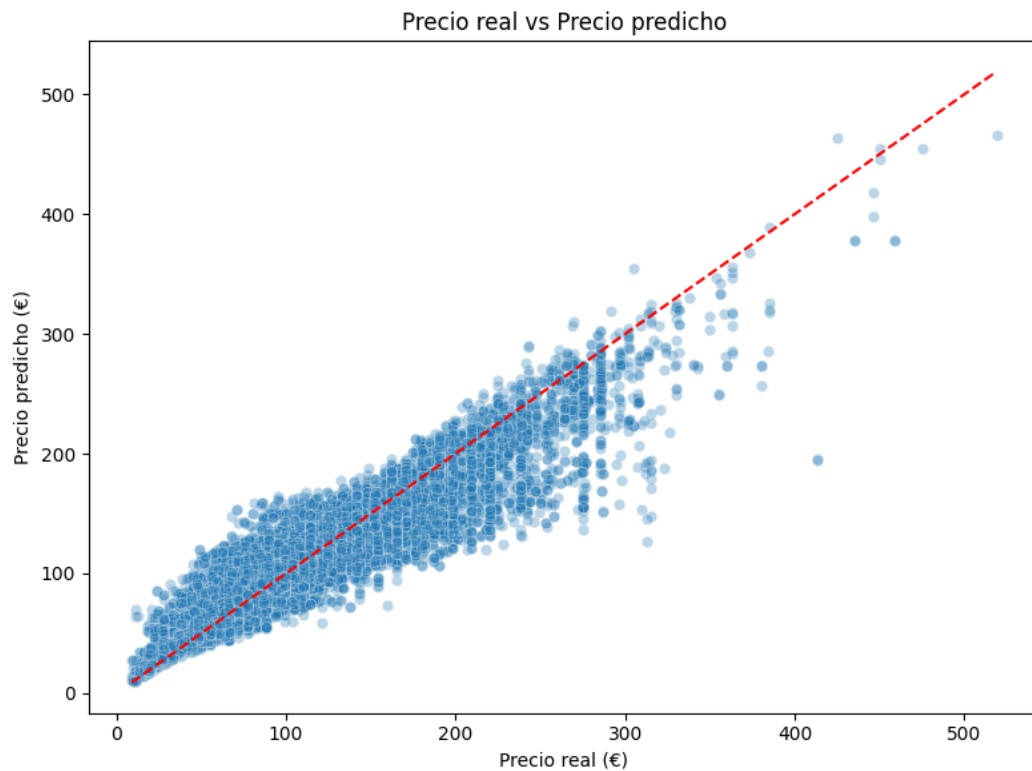


Ilustración 12. Comparación entre precio real y precio predicho por el modelo Random Forest. Fuente: elaboración propia.

Por su parte, la (Ilustración 13) presenta la distribución del error absoluto. La mayoría de los errores se concentran en valores inferiores a 20 €, lo cual es un margen altamente competitivo en el sector turístico.

Este comportamiento valida que el modelo no solo es preciso en promedio, sino también consistente en la mayoría de los casos.

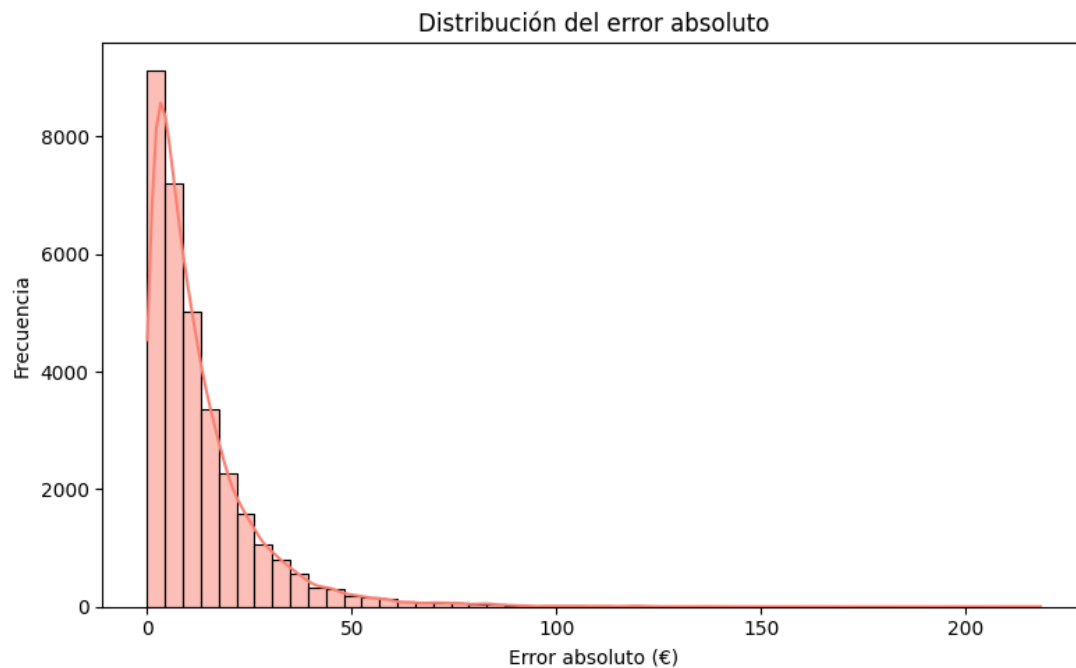


Ilustración 13. Distribución del error absoluto en la predicción de precios. Fuente: elaboración propia.

Desempeño por barrios: El análisis de error absoluto por barrio (Ilustración 14) permite observar diferencias en la calidad de predicción:

- En barrios con gran cantidad de datos (Sol, Justicia, Cortes, Ríos Rosas), el error promedio se mantiene bajo (~15 €).
- En barrios exclusivos como Recoletos, Jerónimos o El Viso, el error es mayor. Esto se debe a la mayor dispersión de precios en mercados de alta gama, donde influyen factores como lujo, exclusividad y servicios adicionales.

El modelo se muestra muy confiable en zonas con alta representatividad de datos, y aunque el error crece en mercados premium, logra capturar adecuadamente las tendencias.

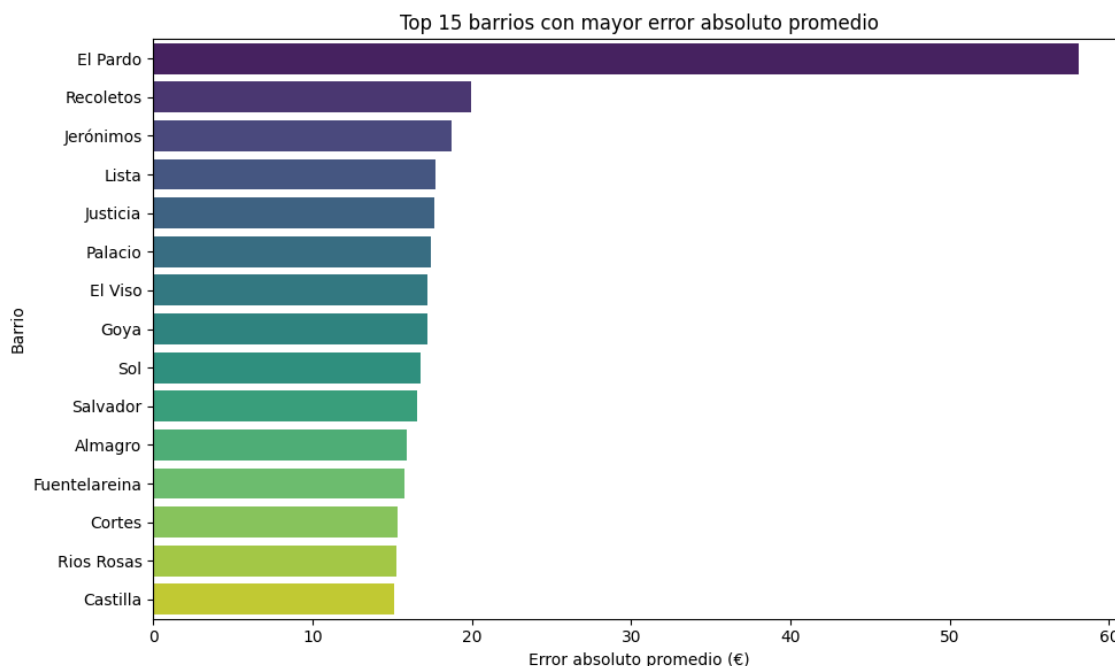


Ilustración 14. Top 15 barrios con mayor error absoluto promedio en la predicción. Fuente: elaboración propia.

Evaluación global del modelo: El modelo fue evaluado en entrenamiento y prueba, mostrando resultados consistentes y sin signos de sobreajuste:

- Entrenamiento (TRAIN): MAE = 11,90 €, RMSE = 18,07 €, $R^2 = 0,895$
- Prueba (TEST): MAE = 12,90 €, RMSE = 18,99 €, $R^2 = 0,883$

- ⇒ El MAE de ~13 € indica predicciones muy cercanas a los valores reales.
- ⇒ El R^2 cercano a 0,90 confirma que el modelo explica casi el 90% de la variabilidad de precios.
- ⇒ La similitud entre métricas de TRAIN y TEST demuestra que el modelo generaliza bien y no sufre de sobreajuste.

Síntesis final del modelo: El modelo Random Forest.

- Ofrece predicciones precisas, con errores promedio bajos y gran capacidad explicativa.
- Identifica claramente las variables clave que determinan el precio (tipo de alojamiento, ubicación y reputación).
- Se adapta bien a distintos contextos urbanos (barrios centrales, periféricos y premium).
- Tiene potencial de ampliación incorporando factores externos como estacionalidad más detallada, eventos en la ciudad o indicadores económicos.

En conclusión, Random Forest se consolida como la mejor alternativa frente a CatBoost y XGBoost, al combinar exactitud, robustez e interpretabilidad, posicionándose como una herramienta útil para anfitriones, gestores turísticos e inversores en el mercado de Airbnb en Madrid.

4.2.7 Interfaz de usuario

Como parte final del desarrollo, se implementó una interfaz interactiva utilizando Streamlit, con el objetivo de hacer el modelo accesible para cualquier usuario sin necesidad de conocimientos técnicos.

La interfaz permite:

- Seleccionar las características del alojamiento (barrio, tipo de alojamiento, número de habitaciones, baños y capacidad de personas).
- Consultar el precio estimado mensual para un mes específico.
- Comparar el precio con otros meses, capturando la estacionalidad.
- Obtener alternativas por barrio, destacando tanto las opciones con precios similares como las más baratas.
- Visualizar en un mapa dinámico las zonas de Madrid según los precios estimados, lo que facilita el análisis espacial.

El diseño sigue una lógica sencilla y user-friendly:

- En el panel lateral (sidebar) se ingresan las características del inmueble.
- En el panel central se muestran los resultados: precio estimado, comparativas mensuales y alternativas por barrio.
- El mapa interactivo añade una dimensión visual y geográfica al análisis, permitiendo ubicar fácilmente las diferencias de precio entre zonas de la ciudad.

Esta estructura garantiza una navegación intuitiva y rápida, incluso para usuarios no expertos en Data Science. Además, el lenguaje empleado es claro, evitando términos técnicos complejos.

- (Ilustración 15). Interfaz principal de la aplicación con predicción de precios, comparativa mensual y alternativas por barrio.
- (Ilustración 16). Mapa dinámico de barrios de Madrid resaltando la zona seleccionada y alternativas.

La interfaz convierte el modelo en una herramienta práctica y aplicable en escenarios reales:

- Para anfitriones, permite ajustar precios de forma competitiva.
- Para turistas, facilita comparar opciones y elegir la mejor alternativa.

Barrio

Argüelles

Tipo de alojamiento

Apartamento entero

Personas

3

Habitaciones

2

Baños

2

Mes

mayo

☒ Comparar con otros meses

Meses a comparar

enero

marzo

junio

Predicción de precio • Airbnb Madrid

Predice, compara y encuentra el precio justo en Airbnb Madrid

Precio estimado en mayo

208 €

Comparativa por meses

Mes	Precio (estimado)	seleccionado
mayo	208 €	<input checked="" type="checkbox"/>
enero	207 €	<input type="checkbox"/>
marzo	207 €	<input type="checkbox"/>
junio	207 €	<input type="checkbox"/>
septiembre	206 €	<input type="checkbox"/>
diciembre	206 €	<input type="checkbox"/>

Ningún mes cae en ≤ 50 €. Sugerencia: **septiembre** (~206 €).

> Mín/Máx estimado (estos meses)

Alternativas por barrio

Precios más cercanos al barrio elegido

Barrio	Precio (estimado)	Δ vs elegido
Abrantes	208 €	+0 €
Buenavista	208 €	+0 €

Alternativas más baratas

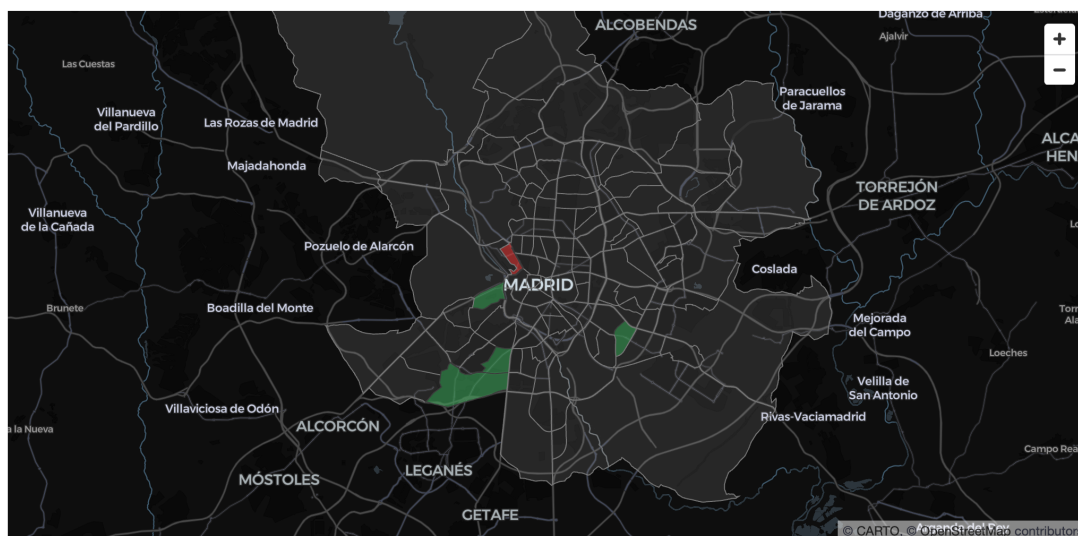
Barrio	Precio (estimado)	Δ vs elegido
Puerta del Angel	184 €	-25 €
Portazgo	184 €	-25 €

Resumen de búsqueda

Tus preferencias:

Barrio: Argüelles | Tipo: Apartamento entero | Personas: 3 | Habitaciones: 2 | Baños: 2 | Mes: mayo | Precio estimado: 208 €

Mapa de barrios



34

4.3 Recursos requeridos

Para la ejecución del proyecto se utilizaron los siguientes recursos:

- Equipo técnico: ordenador portátil personal con capacidad suficiente para el procesamiento de datos y entrenamiento de modelos de Machine Learning.
- Software: ecosistema open-source, principalmente Python y librerías de Data Science (pandas, NumPy, matplotlib, seaborn, plotly, scikit-learn, XGBoost, CatBoost, category_encoders), además del entorno de desarrollo Jupyter Notebook.
- Datos: conjuntos de datos públicos procedentes de la plataforma Inside Airbnb, incluyendo archivos listings.csv y calendar.csv.
- Visualización geográfica: uso de archivos geojson públicos de los barrios de Madrid para la representación espacial de precios.
- Tiempo de trabajo: aproximadamente 200 horas distribuidas en las fases de recolección, limpieza, análisis, modelado, interpretación de resultados y redacción de la memoria.

Este conjunto de recursos permitió garantizar un desarrollo eficiente, sin necesidad de inversión económica adicional, al apoyarse en software libre y en fuentes de datos abiertas.

4.4 Presupuesto

Tipo de coste	Valor	Comentarios
Horas de trabajo en el proyecto (≈ 200)	4.000 €	Estimación a 20 €/h como valor de mercado de trabajo de data scientist junior.
Equipo técnico utilizado	1.200 €	Portátil personal, MacBook Pro.
Software utilizado	0 €	Python, librerías y Streamlit (gratuitos).
Materiales y documentación	0 €	Uso de recursos digitales y datasets públicos.
Total estimado	5.200€	

4.5 Viabilidad

El proyecto resulta económicamente y técnicamente viable, dado que:

- **Costes reducidos:** los gastos fueron mínimos gracias al uso de software open-source (Python, librerías de Data Science, Jupyter Notebook, Streamlit), y a la utilización de

datasets públicos de Inside Airbnb. Únicamente se requirió equipo personal (ordenador portátil), lo que evita inversiones adicionales significativas.

- **Beneficios potenciales:** el modelo ofrece un alto valor añadido para distintos actores:
 - ⇒ **Anfitriones:** pueden optimizar sus ingresos ajustando precios en función de zona, estacionalidad y características de la propiedad.
 - ⇒ **Turistas:** acceden a una referencia objetiva de precios, lo que les facilita identificar oportunidades y evitar sobrecostos.
 - ⇒ **Inversores y gestores inmobiliarios:** disponen de una herramienta de análisis que contribuye a tomar decisiones estratégicas más fundamentadas sobre dónde y cuándo invertir.
- **Escalabilidad y sostenibilidad:** la metodología es replicable en otras ciudades o plataformas de alquiler vacacional, lo que multiplica su aplicabilidad. Asimismo, el uso de tecnologías abiertas garantiza que el sistema pueda mantenerse y evolucionar a futuro sin dependencia de licencias de pago.

En conjunto, la relación coste/beneficio es altamente favorable, con una inversión reducida (5.200 € estimados), se logra un modelo robusto, de gran utilidad práctica y con un horizonte de aplicación sostenible en el tiempo.

4.6 Resultados del proyecto

El proyecto no solo alcanzó métricas sólidas en términos de predicción, sino que también permitió extraer conocimiento valioso sobre el comportamiento del mercado de alojamientos turísticos en Madrid.

Uno de los hallazgos más relevantes fue la confirmación del peso de tres dimensiones clave en la fijación de precios:

1. Estructura del alojamiento (tipo de vivienda, número de habitaciones y capacidad).
2. Ubicación geográfica (diferencias significativas entre barrios céntricos y periféricos).
3. Estacionalidad (variaciones en función del mes, asociadas a la dinámica turística de la ciudad).

Más allá de los indicadores numéricos, el modelo demostró que es posible construir un sistema de apoyo a la decisión que:

- Sugiere precios realistas a anfitriones para maximizar ocupación y rentabilidad.
- Permite a turistas identificar zonas más asequibles o con mejor relación calidad-precio.
- Ofrece a inversores una herramienta objetiva para valorar barrios con mayor potencial de rentabilidad.

Además, el proceso de análisis exploratorio y limpieza evidenció que el mercado presenta anomalías y errores de registro (ejemplo: anuncios con precios irreales superiores a 20.000 € por noche). Detectar y corregir estos casos no solo mejora la calidad del modelo, sino que también aporta una visión más transparente del ecosistema Airbnb en Madrid.

En términos metodológicos, el proyecto mostró la importancia de combinar fuentes y enfoques: la unión de listings con calendar enriqueció el dataset y permitió capturar la estacionalidad, mientras que la comparación de algoritmos evidenció fortalezas y limitaciones de cada enfoque, consolidando a Random Forest como la mejor opción por su balance entre precisión, estabilidad y facilidad de interpretación.

En definitiva, los resultados finales no deben entenderse únicamente como un modelo predictivo exitoso, sino como la base de una solución práctica y escalable, con impacto directo en la gestión del mercado turístico y con capacidad de extenderse a otros destinos urbanos.

Capítulo 5. DISCUSIÓN

El desarrollo de este proyecto ha permitido obtener un modelo predictivo robusto para estimar precios de alojamientos en Airbnb Madrid. No obstante, más allá de los resultados cuantitativos alcanzados, es necesario reflexionar sobre los alcances, limitaciones y aprendizajes obtenidos durante el proceso.

5.1 Utilidad y pertinencia de la metodología

La metodología CRISP-DM aplicada demostró ser adecuada para estructurar el proyecto en fases claras: comprensión, preparación, análisis, modelado y evaluación. Esta organización permitió mantener una línea de trabajo coherente y replicable.

- La fase de preparación de datos fue especialmente crítica, dado el volumen de inconsistencias, outliers y datos nulos presentes en los datasets originales de Inside Airbnb.
- El enfoque modular de CRISP-DM permitió introducir cambios sin perder coherencia, como la decisión de realizar eliminaciones de outliers tanto globales como por barrio.

En términos generales, la metodología inicial ha sido útil y aplicable, aunque requirió ajustes para adaptarse a la naturaleza particular del dataset.

5.2 Limitaciones del estudio

A pesar de los resultados positivos, el proyecto presenta limitaciones que deben considerarse:

- **Cobertura temporal:** los datos disponibles corresponden a un periodo concreto y no incluyen históricos suficientemente amplios como para modelar tendencias de largo plazo.
- **Variables exógenas no consideradas:** factores como eventos culturales, deportivos o crisis económicas (p. ej., pandemia) no están reflejados en los datos, aunque tienen un impacto directo en los precios.
- **Heterogeneidad de barrios premium:** en zonas exclusivas como Recoletos, Jerónimos o El Viso, el modelo presenta mayor error debido a la elevada dispersión de precios y menor cantidad de registros representativos.

Estas limitaciones no invalidan los resultados, pero marcan áreas de mejora para futuros trabajos.

5.3 Limitaciones tecnológicas

El uso de herramientas open-source (Python, scikit-learn, CatBoost, XGBoost, Streamlit) garantizó viabilidad y replicabilidad. Sin embargo, también existen limitaciones técnicas:

- **Escalabilidad:** el modelo funciona de manera eficiente con datasets de Madrid, pero requeriría optimización para aplicarse a múltiples ciudades en tiempo real.
- **Infraestructura:** al trabajar con entornos de desarrollo locales y gratuitos, no se dispuso de recursos avanzados en la nube que permitirían mayor rendimiento y despliegue más sofisticado.
- **Visualización:** aunque las librerías utilizadas (matplotlib, seaborn, plotly) fueron suficientes, la integración con herramientas de BI más potentes (como Power BI o Tableau) podría enriquecer la experiencia de usuario final.

5.4 Adaptaciones y cambios en el desarrollo

Durante el proyecto se realizaron ajustes relevantes respecto a los objetivos iniciales:

- Se redujo el alcance a un modelo centrado exclusivamente en la predicción de precios, en lugar de abarcar otros factores como capacidad o segmentación de usuarios.
- Se incorporó la estacionalidad a través del dataset calendar.csv, lo cual no estaba contemplado en la primera versión del planteamiento.
- Se decidió implementar una interfaz interactiva en Streamlit, lo que transformó el proyecto de un análisis académico a una herramienta práctica y accesible.

Estos cambios fueron necesarios y enriquecieron el producto final, alineándolo mejor con las necesidades reales de anfitriones, turistas e inversores.

5.5 Impacto y valor del proyecto

El resultado del proyecto tiene un impacto directo en distintos actores del mercado turístico:

- Para anfitriones, el modelo facilita fijar precios competitivos que maximizan la ocupación.
- Para turistas, mejora la transparencia y permite comparar alternativas con facilidad.
- Para inversores, ofrece una herramienta que ayuda a identificar zonas con mayor potencial de rentabilidad.

Más allá de lo técnico, el proyecto refleja la capacidad de aplicar Data Science a un problema real, aportando valor tanto académico como práctico.

Capítulo 6. CONCLUSIONES

6.1 Conclusiones del trabajo

El objetivo general del proyecto fue desarrollar un sistema de predicción inteligente de precios de alojamientos en Airbnb Madrid, integrando variables relacionadas con la ubicación, características del inmueble, anfitriones y factores estacionales.

Los resultados obtenidos permiten concluir que:

- El modelo de Random Forest alcanzó un desempeño sobresaliente, con un MAE de 12.90 €, un RMSE de 18.99 € y un R^2 de 0.883, lo que lo posiciona como la mejor opción frente a CatBoost y XGBoost.
- El modelo es capaz de predecir precios con un alto nivel de fiabilidad, ofreciendo estimaciones útiles para la toma de decisiones en un mercado altamente competitivo como el de Madrid.
- La metodología aplicada (limpieza de datos, eliminación de outliers, incorporación de estacionalidad y selección de algoritmos) ha demostrado ser efectiva para garantizar la calidad de los resultados.
- El sistema desarrollado beneficia a distintos actores: anfitriones, que pueden fijar precios más competitivos; turistas, que disponen de referencias más justas; e inversores, que pueden identificar oportunidades de rentabilidad en diferentes barrios.

En síntesis, se ha cumplido plenamente con el objetivo general y los objetivos específicos del proyecto, validando la utilidad de modelos de Machine Learning para optimizar la gestión de precios en plataformas de economía colaborativa.

6.2 Conclusiones personales

El desarrollo de este trabajo ha representado un reto académico y profesional significativo. La complejidad de los datos, la necesidad de adaptar metodologías y la comparación de distintos modelos han enriquecido mi experiencia como futura profesional en Data Science.

De forma personal, este proyecto me ha permitido:

- Consolidar conocimientos técnicos en análisis de datos, modelado predictivo y validación de resultados.
- Desarrollar habilidades de gestión de proyectos, organización del trabajo y toma de decisiones ante imprevistos.

- Confirmar la relevancia de aplicar la ciencia de datos en contextos reales, donde las soluciones no solo generan valor económico, sino que también tienen un impacto social en la experiencia de usuarios y en la sostenibilidad del turismo.

En lo personal, este trabajo ha sido un proceso de aprendizaje profundo y de crecimiento, reforzando mi interés por seguir desarrollándome en el ámbito del análisis predictivo y la inteligencia artificial aplicada a problemas del mundo real.

Capítulo 7. FUTURAS LÍNEAS DE TRABAJO

Durante el desarrollo del presente proyecto se identificaron diversas oportunidades de mejora y ampliación que, por cuestiones de alcance y tiempo, no pudieron abordarse, pero que representan caminos prometedores para potenciar el valor del modelo desarrollado:

- **Integración de datos en tiempo real:** conectar la solución con la API de Airbnb u otras fuentes de datos externas para actualizar continuamente precios, disponibilidad y tendencias del mercado.
- **Ampliación del alcance geográfico:** extender el modelo a otras ciudades españolas o europeas con alto flujo turístico, permitiendo comparativas más amplias y robustas.
- **Optimización de hiperparámetros:** aplicar técnicas más avanzadas como Bayesian Optimization o Grid/Random Search para refinar el rendimiento de los modelos y reducir aún más el error.
- **Incorporación de variables adicionales:** incluir factores externos como festividades locales, grandes eventos, datos de transporte o nivel de contaminación, que pueden influir en la demanda y los precios.
- **Desarrollo de un sistema de recomendación completo:** evolucionar el prototipo hacia una herramienta interactiva para anfitriones, inversores y turistas, con funcionalidades de simulación de escenarios y recomendaciones personalizadas.
- **Visualización avanzada:** implementar dashboards interactivos en plataformas como Streamlit o Tableau que faciliten el análisis dinámico de los resultados por parte de distintos perfiles de usuario.

En conclusión, este trabajo abre la puerta a un amplio espectro de líneas de investigación y desarrollo, que podrían consolidar una solución más integral, escalable y con mayor aplicabilidad práctica en la toma de decisiones dentro del mercado de alquiler turístico.

Capítulo 8. REFERENCIAS

[1] Inside Airbnb. Get the Data. Disponible en: <http://insideairbnb.com/get-the-data.html>
[Accedido: 15-jul-2025].

[2] Scikit-learn. Machine Learning in Python. Disponible en: <https://scikit-learn.org/stable/>
[Accedido: 20-jul-2025].

[3] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), pp. 785–794, 2016.

[4] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, Andrey Gulin. “CatBoost: unbiased boosting with categorical features.” Advances in Neural Information Processing Systems (NeurIPS), 2018.

[5] J. Friedman, T. Hastie, R. Tibshirani. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer, 2009.

[6] Wes McKinney, “Data Structures for Statistical Computing in Python,” Proceedings of the 9th Python in Science Conference (SciPy), pp. 56–61, 2010.

[7] Seaborn. Statistical Data Visualization. Disponible en: <https://seaborn.pydata.org/>
[Accedido: 20-jul-2025].

[8] Plotly. Plotly Python Graphing Library. Disponible en: <https://plotly.com/python/>
[Accedido: 25-jul-2025].

[9] Streamlit. The fastest way to build and share data apps. Disponible en: <https://streamlit.io/>
[Accedido: 10-ago-2025].

[10] R. Kohavi, “A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection,” Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI), pp. 1137–1145, 1995.

[11] M. Wirth, “CRISP-DM: Towards a Standard Process Model for Data Mining,” Proceedings of the 4th International Conference on the Practical Application of Knowledge Discovery and Data Mining (PADD), 2000.

[12] AENOR, Norma UNE 157001: Criterios generales para la elaboración de proyectos. Madrid: AENOR, 2002.

Capítulo 9. ANEXOS

Todo el material complementario del proyecto (código fuente, notebooks, datasets procesados y visualizaciones adicionales) se encuentra disponible en el repositorio de GitHub asociado a este trabajo:

 [Repositorio GitHub – Predicción de precios Airbnb Madrid](#)

